Natural Language Processing – Projet

Analyse de sentiments

Afin de clôturer notre formation en Natural Language Processing, il nous a été demandé de faire un projet sur l'analyse de sentiments. L'analyse de sentiments peut s'avérer très utile, notamment pour une entreprise, dans le but de recueillir des informations sur ce que pensent leurs clients. L'objectif est, à partir d'un texte (dans notre cas des tweets), de déterminer s'il est positif ou négatif. Plutôt que d'analyser manuellement chaque tweet un par un, il peut alors être très pratique d'établir un modèle qui peut analyser automatiquement ces tweets et dire si ces derniers sont plutôt positifs ou plutôt négatifs, avec une certaine précision. Ces prédictions peuvent ensuite servir comme indicateurs pour de potentielles améliorations.

Notre objectif est donc de créer un modèle d'analyse de sentiments et de l'entraîner, le but étant, à l'issue de cet entraînement, de pouvoir prédire le sentiment d'un texte avec ce modèle.

Voici donc comment va se découper notre projet pour l'analyse de sentiments :

I. Importation des données
II. Prétraitement des données
III. Préparation des données pour l'entraînement
IV. Création du modèle, entraînement
V. Tests de prédiction

I. Importation des données

La première étape est d'importer nos données. Les données que nous utilisons sont présentes dans un fichier .csv : *training.1600000.processed.noemoticon.csv*

Ce jeu de données comporte 1 600 000 tweets, tous répertoriés comme positifs ou négatifs.

	target	id	date	flag	user	text
0	0	1467810369	Mon Apr 06 22:19:45 PDT 2009	NO_QUERY	_TheSpecialOne_	@switchfoot http://twitpic.com/2y1zl - Awww, t...
1	0	1467810672	Mon Apr 06 22:19:49 PDT 2009	NO_QUERY	scotthamilton	is upset that he can't update his Facebook by ...
2	0	1467810917	Mon Apr 06 22:19:53 PDT 2009	NO_QUERY	mattycus	@Kenichan I dived many times for the ball. Man...
3	0	1467811184	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	ElleCTF	my whole body feels itchy and like its on fire
4	0	1467811193	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	Karoli	@nationwideclass no, it's not behaving at all....
...	...	...	...	...	...	...
1599995	4	2193601966	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	AmandaMarie1028	Just woke up. Having no school is the best fee...
1599996	4	2193601969	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	TheWDBoards	TheWDB.com - Very cool to hear old Walt interv...
1599997	4	2193601991	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	bpbabe	Are you ready for your MoJo Makeover? Ask me f...
1599998	4	2193602064	Tue Jun 16 08:40:49 PDT 2009	NO_QUERY	tinydiamondz	Happy 38th Birthday to my boo of alll time!!! ...
1599999	4	2193602129	Tue Jun 16 08:40:50 PDT 2009	NO_QUERY	RyanTrevMorris	happy #charitytuesday @theNSPCC @SparksCharity...

1600000 rows × 6 columns

Ci-dessus, un aperçu des données que nous avons à disposition : un tableau de 6 colonnes :

- target : 0 ou 4, valeurs définissant le sentiment du tweet (0 = tweet négatif, 4 = tweet positif)
- id : identifiant du tweet
- date : date du tweet
- flag : la validité du tweet (tous à NO_QUERY : les tweets sont tous valides)
- user : l'utilisateur ayant posté le tweet
- text : le tweet en question

Pour notre application, les seules données qui nous intéressent sont les tweets et les sentiments. Nous ne gardons donc que ces deux colonnes pour la suite.

II. Prétraitement des données

Afin de faciliter le futur traitement des données, il faut traiter tous les tweets pour qu'ils soient plus facilement lisibles. Nous allons donc utiliser plusieurs traitements pour "nettoyer" les tweets :

- On supprime les liens (www., httpss://, etc)
- On supprime les mentions (@utilisateur)
- On supprime les espaces vides
- On supprime les hashtags
- On supprime les ponctuations (on ne garde que les lettres)
- On met toutes les lettres en minuscule
- Grâce à un dictionnaire de stopwords (qui sont les mots qui ne sont pas fondamentalement importants dans la phrase), on supprime les stopwords

```
text = text.str.replace('[^a-zA-Z#]',' ') # keep only letters, if not a letter replace with space
text = text.str.lower() #remove uppercases letters
text = text.apply(lambda x: ' '.join(w for w in x.split() if w not in stopWords)) # remove stopwords
text = re.sub('((www\.[^\s]+)|(https?://[^\s]+))',' ',text) #remove links
text = re.sub('@[^\s]+',' ', text) #remove mentions
text = re.sub('[\s]+', ' ', text) #remove blanks
text = re.sub(r'#([^\s]+)', r' ', text) #remove #
```

text	clean_tweet
@switchfoot http://twitpic.com/2y1zl - Awww, t...	awww bummer shoulda got david carr third day
is upset that he can't update his Facebook by ...	upset update facebook texting might cry result...
@Kenichan I dived many times for the ball. Man...	dived many times ball managed save rest go bounds
my whole body feels itchy and like its on fire	whole body feels itchy like fire
@nationwideclass no, it's not behaving at all....	behaving mad see
...	...
Just woke up. Having no school is the best fee...	woke school best feeling ever
TheWDB.com - Very cool to hear old Walt interv...	thewdb com cool hear old walt interviews
Are you ready for your MoJo Makeover? Ask me f...	ready mojo makeover ask details
Happy 38th Birthday to my boo of alll time!!! ...	happy th birthday boo alll time tupac amaru sh...
happy #charitytuesday @theNSPCC @SparksCharity...	happy

Ainsi nous obtenons des tweets propres, avec seulement les informations essentielles à l'intérieur

Ensuite, nous voulons appliquer le Stemming à nos tweets. Le but du Stemming (enraciment en français) est d'obtenir une forme tronquée d'un mot commune à toutes les variantes possibles de ce mot, c'est-à-dire d'obtenir le mot "racine", le mot de base. Exemple : feels, felt, feeling => mot racine = feel

Pour procéder, nous devons tokenizer tous nos tweets, c'est à dire découper nos phrases en tableaux de mots :

```
0    [awww, bummer, shoulda, got, david, carr, thir...
1    [upset, update, facebook, texting, might, cry,...
2    [dived, many, times, ball, managed, save, rest...
3              [whole, body, feels, itchy, like, fire]
4                                  [behaving, mad, see]
```

A présent on parcourt tous les mots et on applique le Stemming :

```
0    [awww, bummer, shoulda, got, david, carr, thir...
1    [upset, updat, facebook, text, might, cri, res...
2    [dive, mani, time, ball, manag, save, rest, go...
3              [whole, bodi, feel, itchi, like, fire]
4                                   [behav, mad, see]
```

On crée une nouvelle colonne pour une visualisation

text	clean_tweet	tokens
@switchfoot http://twitpic.com/2y1zl - Awww, t...	awww bummer shoulda got david carr third day	[awww, bummer, shoulda, got, david, carr, thir...
is upset that he can't update his Facebook by ...	upset update facebook texting might cry result...	[upset, updat, facebook, text, might, cri, res...
@Kenichan I dived many times for the ball. Man...	dived many times ball managed save rest go bounds	[dive, mani, time, ball, manag, save, rest, go...
my whole body feels itchy and like its on fire	whole body feels itchy like fire	[whole, bodi, feel, itchi, like, fire]
@nationwideclass no, it's not behaving at all....	behaving mad see	[behav, mad, see]
...	...	...
Just woke up. Having no school is the best fee...	woke school best feeling ever	[woke, school, best, feel, ever]
TheWDB.com - Very cool to hear old Walt interv...	thewdb com cool hear old walt interviews	[thewdb, com, cool, hear, old, walt, interview]
Are you ready for your MoJo Makeover? Ask me f...	ready mojo makeover ask details	[readi, mojo, makeov, ask, detail]
Happy 38th Birthday to my boo of alll time!!! ...	happy th birthday boo alll time tupac amaru sh...	[happi, th, birthday, boo, alll, time, tupac, ...
happy #charitytuesday @theNSPCC @SparksCharity...	happy	[happi]

On rassemble les tokens pour créer les phrases finales traitées, et on les met dans une nouvelle colonne appelée *'clean_tweet_final'*

clean_tweet	tokens	clean_tweet_final
awww bummer shoulda got david carr third day	[awww, bummer, shoulda, got, david, carr, thir...	awww bummer shoulda got david carr third day
upset update facebook texting might cry result...	[upset, updat, facebook, text, might, cri, res...	upset updat facebook text might cri result sch...
dived many times ball managed save rest go bounds	[dive, mani, time, ball, manag, save, rest, go...	dive mani time ball manag save rest go bound
whole body feels itchy like fire	[whole, bodi, feel, itchi, like, fire]	whole bodi feel itchi like fire
behaving mad see	[behav, mad, see]	behav mad see
...	...	...
woke school best feeling ever	[woke, school, best, feel, ever]	woke school best feel ever
thewdb com cool hear old walt interviews	[thewdb, com, cool, hear, old, walt, interview]	thewdb com cool hear old walt interview
ready mojo makeover ask details	[readi, mojo, makeov, ask, detail]	readi mojo makeov ask detail
happy th birthday boo alll time tupac amaru sh...	[happi, th, birthday, boo, alll, time, tupac, ...	happi th birthday boo alll time tupac amaru sh...
happy	[happi]	happi

Nos données sont maintenant toutes traitées. La prochaine étape est de les préparer pour l'entraînement.

III. Préparation des données pour l'entraînement

Pour une question de lecture, nous choisissons de modifier toutes les valeurs de target valant 4 en 1. Ainsi, 0 = tweet négatif, 1 = tweet positif

Nous créons ensuite deux jeux de données, data_pos et data_neg, respectivement les données positives et les données négatives. Pour entraîner notre modèle, nous n'allons sélectionner que 40000 tweets positifs et 40000 tweets négatifs, donc un total de 80000 tweets. En effet, entraîner le modèle avec les 1600000 tweets prendrait beaucoup trop de temps pour les tests, surtout si on veut faire un minimum d'époques pour l'entraînement du modèle (Pour mon dernier test, j'ai pris 50000 de chaque)

```
#data_pos from 800000 to 1599999
data_pos = df[df['target'] == 1]
#data_neg from 0 to 799999
data_neg = df[df['target'] == 0]

# for training, keep only 40000 elements of neg and pos
data_neg_test = data_neg.iloc[:int(40000)] # 40000 neg tweets
data_pos_test = data_pos.iloc[:int(40000)] # 40000 pos tweets

# For tests we keep only 80000 elements
data = pd.concat([data_neg_test, data_pos_test])
```

Puis nous définissons nos données d'entrée : x sera les textes et y les sentiments

Il faut maintenant transformer nos mots en vecteurs de mots.

max_len représente le nombre maximum de mots sélectionnés pour l'entrainement. Ces mots seront utilisés selon l'importance qui distingue les tweets positifs et négatifs. Nous en choisissons 500.

Ensuite, nous définissons le Tokenizer, pour lequel nous choisissons un *num_words* de 2000, c'est-à-dire que celui-ci n'utilisera que les 2000 mots les plus communs dans le jeu de données. Le tokenizer crée des tokens pour chaque mot du jeu de données et les mappe à un index à l'aide d'un dictionnaire. On utilise alors la méthode *fit_on_texts*, qui crée l'index de vocabulaire basé sur la fréquence des mots.

Pour notre modèle, il est nécessaire que les données d'entrée soient codées en entiers, de sorte que chaque mot soit représenté par un entier unique. C'est pour cela que nous utilisons la fonction *texts_to_sequences*, qui transforme chaque texte en une séquence d'entiers. Chaque mot du texte est alors remplacé par sa valeur entière correspondante dans le dictionnaire *fit_on_texts*
Etant donné que nous allons construire un modèle séquentiel, alimenté par des séquences de nombres, nous devons nous assurer que les séquences en entrée auront toutes la même forme, elles doivent toutes avoir la même longueur. Le problème est que les textes des tweets ont un nombre de mots différent. Pour pallier ce problème, nous utilisons la fonction *pad_sequence* de *keras*, qui transforme toute la séquence dans une longueur constante *max_len*.

vocab_size représente le nombre total de mots dans le jeu de données

```
max_len = 500
tokenizer = Tokenizer(num_words = 2000) # Tokenizer will use only 2000 most common words
tokenizer.fit_on_texts(x)
sequences = tokenizer.texts_to_sequences(x)
sequences_matrix = sequence.pad_sequences(sequences,maxlen=max_len)

vocab_size = len(tokenizer.word_index)
print("Total words", vocab_size)
print("Matrix shape", sequences_matrix.shape)
```

```
Total words 33555
Matrix shape (80000, 500)
```

Puis nous définissons nos données de l'entrainement et nos données de test.

Pour cela on utilise la fonction *train_test_split* de *sklearn*, qui mélange le jeu de données et le divise. Cette fonction prend un paramètre appelé *test_size*, qui correspond à la portion du jeu de données que nous souhaitons assigner aux données de test. Nous choisissons d'assigner 20% du jeu de données aux données de test, d'où le 0.2

x_train, x_test, y_train, y_test = train_test_split(sequences_matrix, y, test_size=0.2, random_state=2)

Avec un jeu de données de 80000 tweets, on a donc les portions suivantes :

```
x_train : (64000, 500)
y_train : (64000, 1)
x_test : (16000, 500)
y_test : (16000, 1)
```

IV. Création du modèle, entraînement

Nos données sont prêtes, il faut maintenant passer à la création du modèle pour l'entraînement.
Pour notre modèle, nous voulons simplement plusieurs couches (layers), chacune ayant des vecteurs d'entrée et de sortie. Nous utilisons donc un modèle séquentiel, qui est approprié pour cela.

- Etape 1 : L'entrée du modèle est de longueur max_len mots car il s'agit du nombre de mots que nous avons choisis d'extraire du texte des tweets.

- Etape 2 : Nous ajoutons une couche Embedding (un layer de *keras*), avec une taille de *vocab_size* mots, un espace vectoriel de 64 dimensions dans lequel les mots seront incorporés, et des entrées de *max_len* (500) mots chacun. La couche Embedding permet de représenter les mots par des vecteurs où un vecteur représente la projection du mot dans un espace vectoriel continu. La position d'un mot dans l'espace vectoriel est apprise à partir du texte en entrée et est basée sur les mots qui entourent le mot lorsqu'il est utilisé.

- Etape 3 : La couche LSTM transforme la séquence vectorielle sortant de Embedding en un seul vecteur de taille 32, contenant des informations sur la séquence entière. L'objectif de la couche LSTM est d'apprendre à notre modèle quelles informations stocker dans la mémoire à long terme et de quoi se débarrasser. Elle enregistre les mots et prédit les mots suivants en fonction des mots précédents. LSTM est un prédicteur de séquence des prochains mots à venir.

- Etape 4 : La couche Dense est une couche de réseau neuronal qui est profondément connectée, ce qui signifie que chaque neurone de la couche Dense reçoit une entrée de tous les neurones de la couche précédente. Nos couches Dense effectuent des multiplications matrice-vecteur, et elles sont utilisées pour améliorer la précision. Cette couche envoie 256 sorties

- Etape 5 : La fonction d'activation *'relu'* renvoie l'activation ReLU standard : le maximum entre 0 et la valeur d'entrée. Elle aide à décider quel neurone doit passer et quel neurone doit se déclencher

- Etape 6 : Avec la couche Dropout, des neurones sélectionnés au hasard sont ignorés pendant l'entraînement. L'effet est que le réseau devient moins sensible aux poids spécifiques des neurones, et donc capable d'une meilleure généralisation

- Etape 7 : Comme l'étape 4, mais on donne seulement 1 sortie au réseau de neurones pour classer le tweet positif ou négatif

- Etape 8 : La fonction d'activation *'sigmoid'* renvoie une valeur proche de zéro pour les petites valeurs (<-5), et pour les grandes valeurs (> 5) le résultat de la fonction se rapproche de 1. Cela nous permet d'obtenir un résultat entre 0 et 1 pour la classification de nos données

```python
def model1():
    model = Sequential()
    inputs = Input(name='inputs',shape=[max_len])# etape 1
    model.add(Embedding(vocab_size, 64, input_length=max_len)) # etape 2
    model.add(LSTM(32)) # etape3
    model.add(Dense(256,name='FC1')) # etape 4
    model.add(Activation('relu')) # etape 5
    model.add(Dropout(0.5)) # etape 6
    model.add(Dense(1,name='out_layer')) # etape 4
    model.add(Activation('sigmoid')) # etape 5
    return model
```

Définition de notre modèle

On compile ensuite notre modèle avec *model.compile()*

```python
model = model1() # on crée notre modèle
model.compile(loss='binary_crossentropy',optimizer='adam',metrics=['accuracy'])
```

Etant donné qu'on utilise seulement 2 classes (texte et sentiment), on utilise *'binary_crossentropy'*

L'optimizer est une fonction utilisée pour modifier les fonctionnalités du réseau neuronal telles que le taux d'apprentissage afin de réduire les pertes. Ainsi, le taux d'apprentissage du réseau de neurones pour réduire les pertes est défini par l'optimizer.

Nous définissons *metrics='accuracy'* car nous allons calculer le pourcentage de prédictions correctes sur toutes les prédictions de l'ensemble de validation.

Enfin nous lançons l'entraînement de notre modèle (modifier le nombre d'époques selon ce qu'on veut). J'ai choisi une *batch_size* de 100 (donc le modèle prend 100 tweets à chaque itération et les entraîne), 50 époques et un *validation_split* de 0,1 ce qui veut dire que nous alimentons les données d'entraînement et obtenons 10% de données pour validation à partir des données d'entraînement

```python
history=model.fit(x_train,y_train,batch_size=100,epochs=50, validation_split=0.1)
print('Entrainement terminé !')
```

On peut ensuite visualiser l'entrainement de notre modèle :

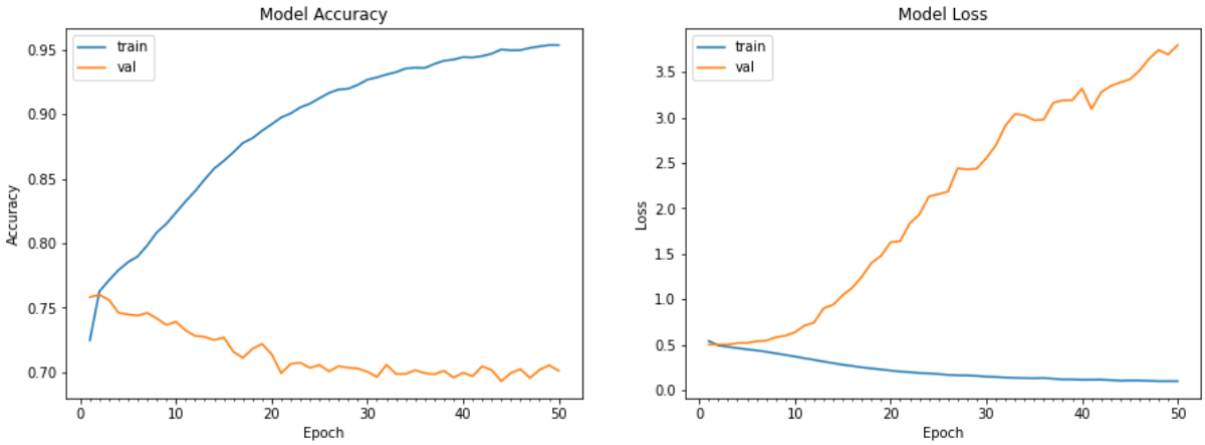

Graphique d'entraînement pour notre modèle, avec 80000 tweets et 50 époques

On a une précision d'environ 0.7034 pour ce modèle (précision obtenue avec *model.evaluate(x_test, y_test, batch_size = 100)*

V. Tests de prédiction

On peut maintenant tester notre modèle avec nos propres phrases. Malheureusement je n'ai pas réussi à intégrer l'API Yelp pour tester mon modèle, j'ai donc décidé de ne pas l'intégrer à mon code et à mon rapport

Pour tester notre pipeline, on crée une fonction *predict* qui a pour fonction d'englober tout le processus et de retourner si le sentiment est positif ou négatif, avec le score

```
def predict(text):
  # clean the text
  textClean = clean_phrase(text)
  # Tokenize text
  x_test = pad_sequences(tokenizer.texts_to_sequences([textClean]), maxlen=max_len)
  # Predict
  score = model.predict([x_test])[0]
  # Decode sentiment
  label = get_sentiment(score)

  return {"Sentiment": label, "Score": float(score)}
```

Dans cette fonction, on traite le texte grâce à la fonction *clean_phrase* (voir ci-dessous) qui reprend les étapes de prétraitement du texte vues à la partie II. Ensuite, la phrase est tokenizée et transformée en vecteurs de mots de la bonne longueur *(max_len)*. Enfin, on prédit le sentiment grâce à notre modèle avec *model.predict()* : si la valeur *score* est inférieure à 0,5 le sentiment est considéré comme négatif, sinon comme positif (c'est la fonction *get_sentiment*)

```
def clean_phrase(text):
  text.replace('[^a-zA-Z#]',' ')
  text.lower()
  text = re.sub('((www\.[^\s]+)|(https?://[^\s]+))',' ',text)
  text = re.sub('@[^\s]+',' ', text)
  text = re.sub('[\s]+', ' ', text)
  text = re.sub(r'#([^\s]+)', r' ', text)
  text = ' '.join(word for word in text.split() if word not in stopWords)
  tokens = text.split()
  tokensStem = [stemmer.stem(i) for i in tokens]
  textClean = ' '.join(tokensStem)

  return textClean
```

Fonction *clean_phrase* reprenant toutes les étapes de traitement vues en partie II

```
predict("I liked the burger")
```

```
{'label': 'Positive sentiment', 'score': 0.9999333620071411}
```

```
predict("Covid is a really sad period")
```

```
{'label': 'Negative sentiment', 'score': 9.69906537306997e-08}
```

On peut voir que les résultats obtenus sont cohérents avec ce à quoi on s'attend.

En ce qui concerne les améliorations possibles, on peut se pencher sur le modèle, peut-être explorer les différents layers disponibles et comparer les résultats de modèles différents.
On pourrait aussi jouer sur les paramètres de compilation et d'entraînement du modèle, qui ont sûrement un gros impact sur la précision. De plus on peut jouer sur la densité du jeu de données d'entraînement et de test.